コンピュータビジョンとその応用

2026年6月7日

目次

1. コンピュータビジョン (CV) とは
2. CVの3大タスク
3. タスクの体験
4. CNNの仕組み

1. コンピュータビジョン (CV) とは

コンピュータビジョン (CV) とは

コンピュータビジョンとは？

→ 画像やビデオなどの視覚的な入力を処理・分析する人工知能の一分野

どんなことに使われているのか？

- 顔認証/顔認識
- 自動運転システム
- 工場での品質欠陥の検知

図1のように人の姿勢を推定することもできる



図1 人物姿勢推定 (引用:ultralytics)

CVで扱う問題の特徴

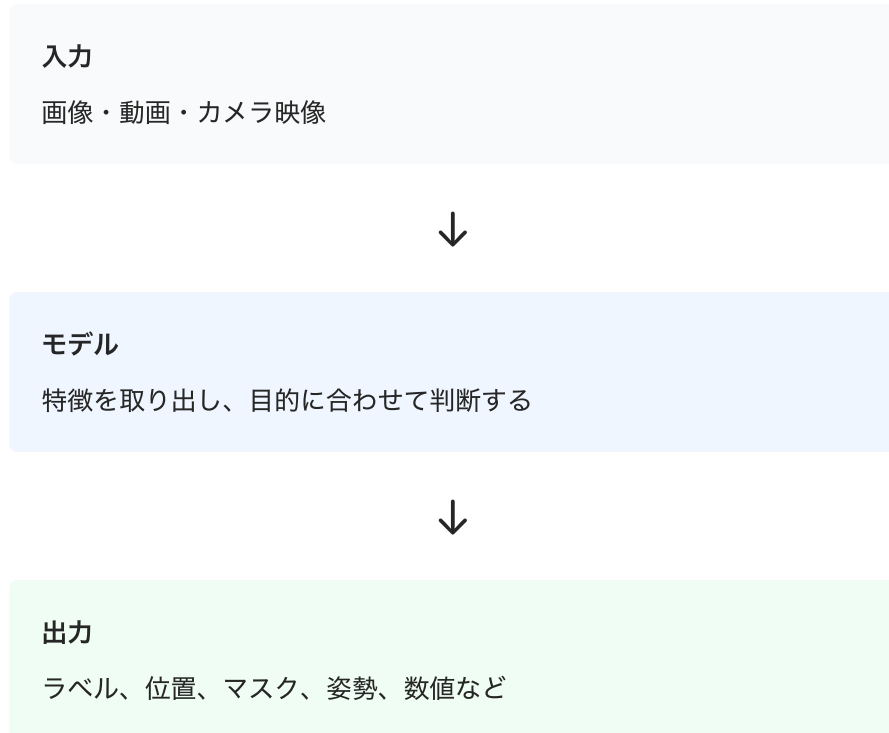
人間には簡単に見える画像理解も、コンピュータには難しい

難しくなる理由

- 同じ物体でも向き・大きさ・明るさが変わる
- 背景や影、手ぶれ、隠れが混ざる
- 画像には「意味」ではなく数値だけが入っている

CVのゴール

- 数値の並びから、人が使える意味へ変換する
- 例: 「車がある」「左車線にいる」「危険かもしれない」



画像とは

コンピュータにとって画像とは？

→ 数値（ピクセル）の配列

グレースケール画像

- 各ピクセル: 0〜255の1つの値

カラー画像 (RGB)

- 各ピクセル: R, G, B の3層
- 各層が0〜255の値を持つ

画像サイズの例

- 28x28の白黒画像: 784個の数値
- 224x224のRGB画像: 150,528個の数値

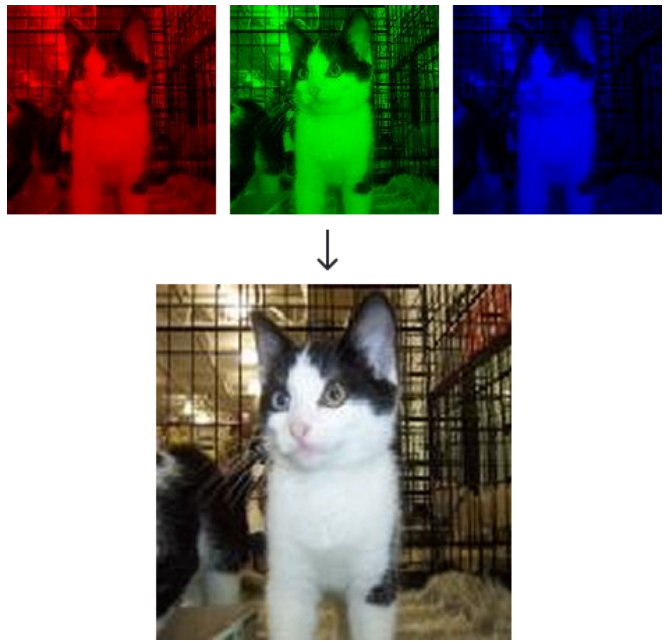


図2 赤・緑・青の層が重なって画像になる様子

機械学習とは

機械学習とは？

→ データからパターンを学習し、予測や判断を行うAIの手法

従来のプログラミング

- ルールを人間が明示的に記述

機械学習

- データから自動的にルールを学習
- ただし、学習データの質に強く依存する

従来のプログラミング:
入力 + ルール → 出力

機械学習:
入力 + 出力 → ルール(モデル)

例: 犬と猫の分類

1. 大量の犬・猫画像を用意
2. 各画像に「犬」「猫」のラベル付け
3. モデルが特徴を自動学習
4. 新しい画像を判定可能に

学習データと評価

モデルは「見たことがあるデータ」にだけ強くなっても意味がない

データの分け方

- 訓練データ: モデルの学習に使う
- 検証データ: 学習中の調整に使う
- テストデータ: 最後に実力を確認する

大切な考え方

- 本番に近いデータで評価する
- 偏ったデータでは、偏った予測になりやすい

データ	役割	例
訓練	パターンを覚える	犬・猫画像8,000枚
検証	設定を調整する	犬・猫画像1,000枚
テスト	最終確認する	犬・猫画像1,000枚

精度が高くても、間違え方を見ることが重要。医療・自動運転・防犯などでは、どの間違いが危険かを先に決めておく。

2. CVの3大タスク

CVの3大タスク

コンピュータビジョンには代表的な3つのタスクがある

タスク	入力	出力
分類	画像全体	カテゴリラベル
検出	画像全体	物体の位置 + ラベル
分割	画像全体	ピクセルごとのラベル

使うタスクは「何を知りたいか」で決まる

3大タスクの使い分け

知りたいこと	選ぶタスク	出力のイメージ	具体例
画像に何が写っているか	分類	「猫」	商品カテゴリ判定
どこに写っているか	検出	四角い枠 + 「人」	防犯カメラの人数確認
どの領域が対象か	分割	対象ピクセルの塗り分け	道路・歩道・車線の認識

分類から分割へ進むほど、出力は細かくなる。一方で、正解データを作る手間も大きくなる。

分類 (Classification)

画像分類とは？

→ 画像全体を1つのカテゴリに分類する

特徴

- この画像は何か？に答える
- 定義したカテゴリに必ず分類される
- 複数の物体がある画像は苦手な場合がある

応用例

- 医療画像の診断補助
- 不良品/良品の判定
- レシートや書類の種類判定



図3 画像分類の例 (引用:ultralytics)

検出 (Detection)

物体検出とは？

→ 画像内の物体の位置と種類を特定する

特徴

- どこに何があるか？に答える
- 定義したカテゴリから選ばれる
- 1枚の画像から複数の物体を同時に見つけられる

応用例

- カメラでの人物検出
- 交通量調査
- 店舗棚の商品数チェック

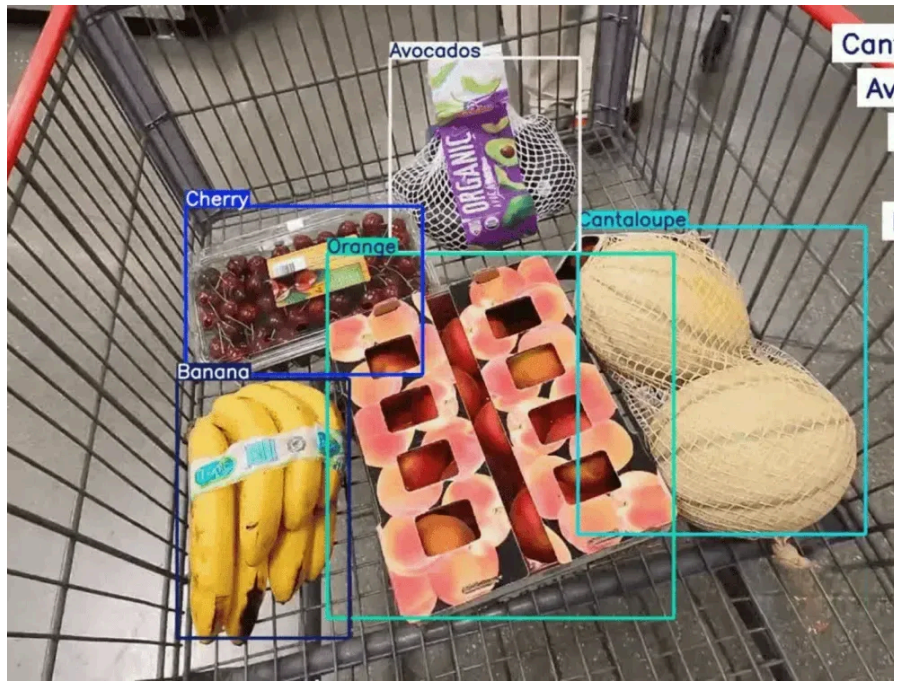


図4 画像検出の例 (引用:ultralytics)

分割 (Segmentation)

セグメンテーションとは？

→ 画像の各ピクセルにラベルを付与する

特徴

- どのピクセルが何か？に答える
- 物体の形を細かく扱える
- 境界を正確に取りたい場面に向いている

応用例

- 自動運転での道路/歩道の認識
- 背景除去・画像編集
- 医療画像での臓器・病変領域の抽出

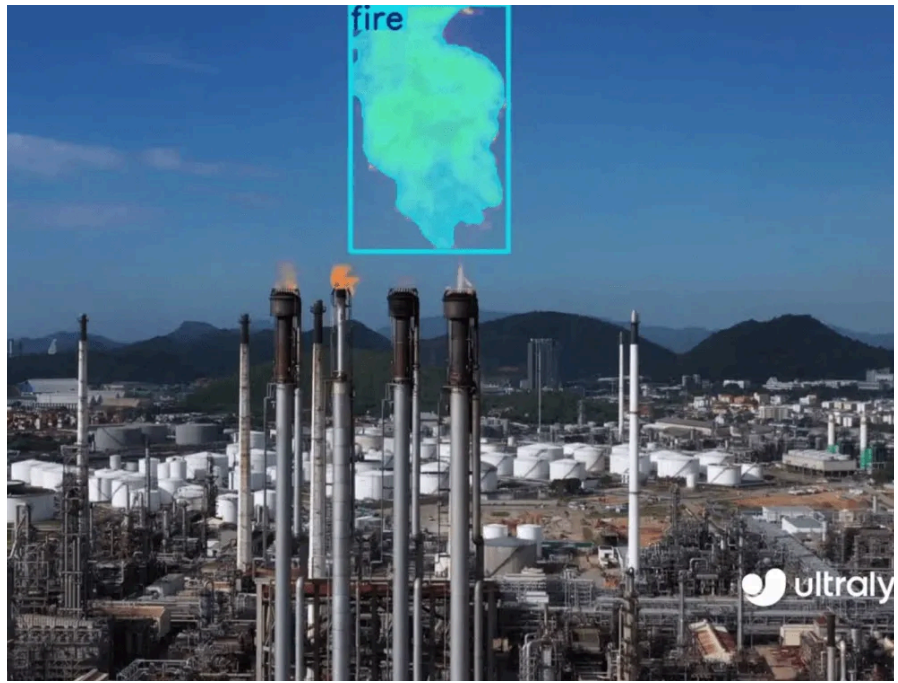


図5 画像分割の例 (引用:ultralytics)

3. タスクの体験

タスクの体験 (Google Colab)

https://trial-class.micanis.dev/13と検索してください

以下のリンクをクリックしてColabを開いてください

Colabで開く

1. 上のリンクをクリック
2. 「ドライブにコピー」で自分のアカウントに保存（任意）
3. 上から順にセルを実行していく

体験で見るポイント

Colabでは「モデルが何を返しているか」を意識して確認する

確認すること	見るポイント
入力画像	何が写っているか、人間には簡単か
予測結果	正解しているか、確信度は高いか
間違い	似た見た目・小さい物体・暗い画像で失敗していないか
処理時間	1枚ずつなら速くても、動画では重くならないか

「なぜ当たったか」だけでなく「どんな時に外れるか」を見ると、実用化の課題が見えやすい。

4. CNNの仕組み

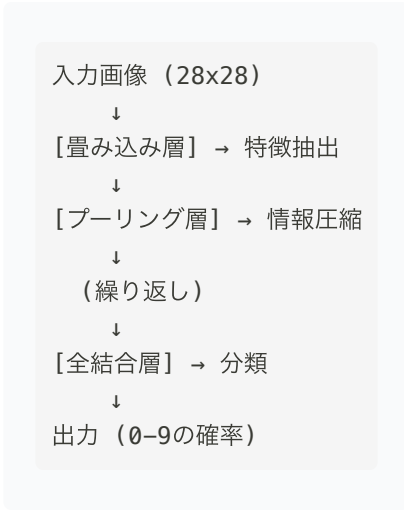
畳み込みニューラルネットワーク (CNN)

CNNとは？

→ 画像認識に特化したニューラルネットワーク

なぜ画像に強いのか？

- 局所的なパターンを検出できる
- 位置がずれても認識できる
- 層を重ねて複雑な特徴を学習
- 画像全体を一度に見るより、近くのピクセル関係を効率よく扱える



畳み込み (Convolution)

畳み込みとは？

→ 小さなフィルタを画像上でスライドさせて特徴を抽出

フィルタの役割

- エッジ（輪郭）を検出
- 特定のパターンを見つける

学習するもの

- フィルタの値は自動で学習される
- 浅い層: エッジ、色
- 深い層: 目、耳、顔全体

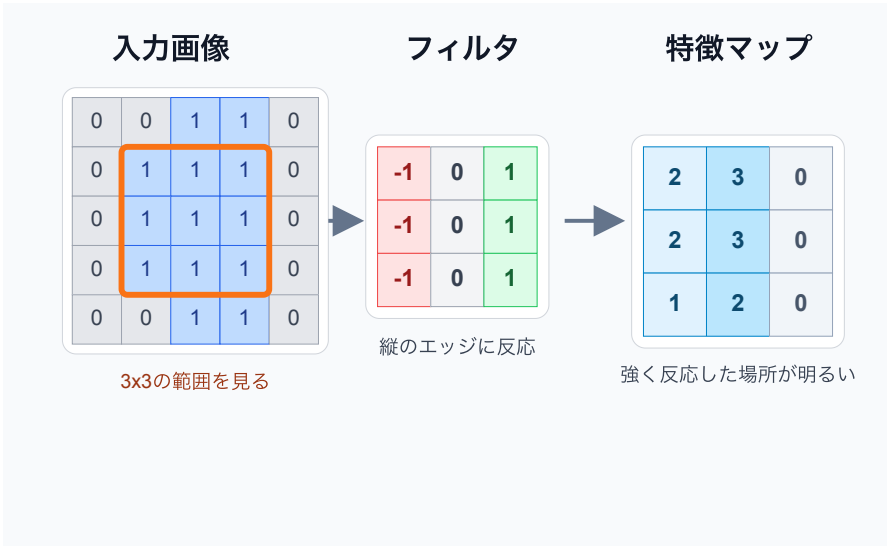


図6 畳み込みの様子

プーリングと全結合層

プーリング

→ 特徴マップを小さくして、重要な反応を残す

効果

- 計算量を減らす
- 少しの位置ずれに強くなる
- 細かすぎる情報を整理する

```
2x2 Max Pooling の例

[1, 3]    →    4
[2, 4]

範囲内で一番強い反応だけを残す
```

畳み込み層は「特徴を探す」、プーリング層は「特徴を整理する」、全結合層は「答えを決める」役割。

CNNの学習で起きていること

学習では、予測の間違いが小さくなるように重みを少しずつ更新する

1回の流れ

1. 画像を入力する
2. モデルが予測する
3. 正解とのズレを計算する
4. ズレが小さくなる方向へ重みを更新する

用語	意味
エポック	訓練データを一通り学習する回数
損失	予測と正解のズレ
精度	正解できた割合
過学習	訓練データだけに合いすぎる状態

訓練精度だけ高く、テスト精度が低い場合は、未知の画像に弱い可能性がある。

CNNを実装してみよう (Google Colab)

以下のリンクをクリックしてColabを開いてください

Colabで開く

1. 上のリンクをクリック
2. 「ドライブにコピー」で自分のアカウントに保存（任意）
3. 上から順にセルを実行していく

CNN実装で確認するポイント

セル	何をしているか	見るポイント
畳み込みの可視化	フィルタで特徴を取り出す	入力・フィルタ・結果の違い
MNIST読み込み	手書き数字データを準備する	画像サイズとラベル
モデル定義	Conv2D / Pooling / Denseを積む	層ごとの出力形状
学習	重みを更新する	lossが下がるか、accuracyが上がるか
予測	未知画像を分類する	確信度と間違い方

実装では「コードが動いた」だけで終わらず、出力の意味を説明できることを目標にする。

参考文献

図	出典
図1	Ultralytics Blog - What is OpenPose
図2	自作
図3	Ultralytics Blog - Image Classification
図4	Ultralytics Blog - Object Detection Models
図5	Ultralytics Blog - Instance Segmentation